

Cranfield Information Retrieval: Modelo Vetorial e BM25

Amanda Bezerra da Costa | 12680861, amandabzrcosta@gmail.com

Leonardo Ferreira Runho | 11832958, <PREENCHER>

Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo
SCC0282 Recuperação da Informação, Prof. Marcelo Manzano, São Carlos, SP,
2026

1 INTRODUÇÃO

A Recuperação de Informação (RI) ordena documentos conforme a relevância para consultas em linguagem natural. Os métodos clássicos de correspondência lexical continuam sendo a base da área. Compreender a representação dos dados e as divergências de ranqueamento ajuda a diagnosticar falhas em sistemas reais. Este trabalho implementa e compara o Modelo Vetorial (TF-IDF com similaridade do cosseno) e o BM25 na coleção Cranfield (1.400 resumos, 225 consultas e julgamentos humanos). O objetivo é avaliar o desempenho médio e analisar os cenários de destaque de cada modelo. A pesquisa investiga o impacto da variação de parâmetros no BM25 e o efeito de reformulações nas buscas. O estudo também diagnostica as causas matemáticas e conceituais dos erros cometidos por esses métodos.

2 TÉCNICAS UTILIZADAS

Pré-processamento. O sistema aplica tokenização com `nltk.word_tokenize`, normalização para minúsculas e descarte de tokens não alfabéticos. A remoção de stopwords (lista do NLTK) e o stemming (Porter) são etapas opcionais. Os compostos hifenizados são divididos em suas partes (`two-dimensional` → `two, dimensional`) para evitar a exclusão de termos técnicos fundamentais filtrados pelo método `isalpha()`, como `boundary-layer`. A divisão unifica grafias intercambiáveis presentes na coleção.

Modelo Vetorial. Documentos e consultas são vetores no espaço de termos. O `TfidfVectorizer` calcula os pesos usando contagem bruta para $tf(t, d)$ e $idf(t) = \ln\left(\frac{1+N}{1+df(t)}\right) + 1$. A normalização L2 garante que a similaridade do cosseno equivalha ao produto escalar. A classe `VectorSpaceModel` centraliza o ranqueamento.

Modelo Probabilístico (BM25). A classe `BM25` implementa o modelo sobre um

índice invertido próprio e soma as contribuições de cada termo:

$$BM25(D, Q) = \sum_{t \in Q} idf(t) \cdot \frac{f(t, D) \cdot (k_1 + 1)}{f(t, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{avgdl}\right)}$$

O IDF é deslocado em +1, com $idf(t) = \ln \left(\frac{N - df(t) + 0,5}{df(t) + 0,5} \right) + 1$. Os parâmetros adotam os valores padrão $k_1 = 1,2$ para saturação e $b = 0,75$ para penalização por comprimento. A média da coleção é de 99,30 tokens.

Organização. Módulos reutilizáveis e notebooks sequenciais garantem a reprodutibilidade integral. A biblioteca `ir_datasets` carrega os dados e possui redundância automática para os arquivos originais em formato SMART.

3 AVALIAÇÃO

A escala de relevância da coleção Cranfield é decrescente. As notas de 1 a 4 indicam relevância. Documentos com nota -1 ou não avaliados são considerados irrelevantes. As métricas binárias (Precision@10, Recall@10 e MAP) agrupam os graus de 1 a 4 como relevantes. O sistema inverte a escala ($5 - r$) para calcular o NDCG@10 e atribuir maior peso às notas melhores. As métricas cobrem as 1.400 posições do ranking e são consolidadas pela média global das 225 buscas. Todos os testes das seções seguintes adotam a configuração conjunta de stopwords e stemming. O ranqueamento ignora os julgamentos de relevância durante sua execução.

4 RESULTADOS OBTIDOS E ANÁLISE

4.1 Efeito do pré-processamento

Tabela 1: Efeito das configurações de pré-processamento

Configuração	Vocabulário	Total de tokens	Tokens/doc	MAP Vetorial	MAP BM25
Sem remoção / sem stemming	6.985	237.586	169,7	0,2729	0,2421
Só remoção de stopwords	6.867	139.013	99,3	0,2790	0,2863
Só stemming	4.361	237.586	169,7	0,2944	0,2620
Stopwords + stemming	4.251	139.013	99,3	0,3015	0,3106

A configuração combinada maximiza o desempenho dos dois modelos (Figura 1). O processamento de texto cru favorece o Modelo Vetorial de forma expressiva. A

remoção de stopwords inverte essa vantagem e posiciona o BM25 na liderança. O cálculo de IDF do BM25 atinge valores negativos para palavras excessivamente frequentes na coleção. Esses termos subtraem pontos dos documentos e injetam ruído direto no ranking. O `TfidfVectorizer` mantém o valor de IDF sempre positivo e sofre apenas degradação leve perante stopwords.

4.2 Comparação agregada entre os modelos

Tabela 2: Métricas agregadas (média sobre 225 consultas)

Métrica	Modelo Vetorial	BM25	Diferença (BM25 - Vetorial)
Precision@10	0,2418	0,2342	-0,0076
Recall@10	0,3987	0,3921	-0,0066
MAP	0,3015	0,3106	+0,0091
F1@10	0,2712	0,2650	-0,0062
MRR	0,5284	0,5455	+0,0170
NDCG@10	0,3497	0,3557	+0,0060

O BM25 ordena com precisão superior os documentos relevantes e lidera as métricas sensíveis à posição (MAP, MRR e NDCG@10). O Modelo Vetorial localiza uma fração levemente maior de arquivos corretos no Top-10 e vence as métricas de conjunto. O placar de Average Precision (AP) apresenta 118 vitórias para o BM25 e 98 para o Vetorial. A vantagem do modelo probabilístico no cálculo de MAP advém de vitórias expressivas em um subconjunto pontual de buscas (Figura 2).

4.3 Análise por consulta

Na consulta 167, a saturação de frequência do BM25 neutraliza um texto irrelevante que repete intensamente um único termo. O Modelo Vetorial utiliza contagem bruta e permite que palavras raras guiem o ranqueamento integralmente. O cenário inverte-se na consulta 17. O Modelo Vetorial premia a especificidade e posiciona um texto curto e correto no topo. O BM25 busca cobertura e elege um arquivo extenso repleto de termos genéricos. As consultas 31 e 22 evidenciam falhas sistêmicas originadas por incompatibilidade de vocabulário e dependência de semântica abstrata.

4.4 Variação dos parâmetros do BM25

A configuração de $b = 0$ elimina a normalização e resulta nas piores pontuações para qualquer valor de k_1 . O incremento de k_1 produz ganhos consistentes com retornos decrescentes (Figura 3). A parametrização empírica ótima atinge MAP de 0,3169

Tabela 3: Casos de consulta selecionados

Consulta	AP BM25	AP Vetorial	Mecanismo
167	0,750	0,091	Saturação de frequência favorece o BM25
173	1,000	0,583	Idem. O Vetorial promove um distrator lexical
17	0,090	0,508	Concentração vetorial favorece o Vetorial
145	0,279	0,583	Idem. O BM25 premia cobertura ampla e rasa
31	0,001	0,001	Ambos falham devido ao descasamento de vocabulário
22	0,002	0,002	Ambos falham devido a relevância puramente conceitual

com $k_1 = 2,0$ e $b = 0,75$. O impacto do parâmetro b oscila de acordo com o contexto da busca. A consulta 65 registra melhora com $b = 0,75$ pois seus documentos relevantes originais são curtos. A consulta 127 sofre quedas com $b \geq 0,75$ porque seus textos corretos possuem alta extensão e sofrem penalização severa.

4.5 Modificação de consultas

Tabela 4: Sobreposição do Top-10 antes/depois da modificação

Consulta	Estratégia	Overlap BM25	Overlap Vetorial
5	Remoção de termo (“hypersonic”)	6/10	5/10
40	Sinônimos (“detect” → “identify”, “hypersonic” → “high-speed”)	3/10	8/10
100	Acréscimo de termo específico (“thin-walled”)	9/10	9/10
150	Remoção de vários termos	7/10	10/10
180	Acréscimo de termo raro (“isothermal”)	10/10	9/10

A troca por sinônimos na consulta 40 causa desestabilização aguda no BM25. A eliminação de palavras de alto IDF subtrai blocos inteiros da pontuação no modelo probabilístico. O Modelo Vetorial redistribui os pesos remanescentes pela normalização vetorial e atesta maior resiliência em exclusões. Inserções de termos raros causam alterações mínimas nas primeiras posições de ambos os modelos.

4.6 Análise de erros

As ferramentas lexicais falham perante limites semânticos:

- **Falso positivo 1 (consulta 31, doc. 751).** O documento lidera o ranqueamento ao compartilhar grande volume de termos, mas descreve o tópico superficialmente sem responder à pergunta quantitativa. O modelo desconhece intenções analíticas.
- **Falso positivo 2 (consulta 173, doc. 532).** A repetição de palavras raras do título projeta o arquivo ao topo. O texto explora aplicações de engenharia e ignora o contexto teórico requerido.
- **Falso negativo (consulta 31, doc. 776).** O arquivo relevante não possui sobreposição vocabular válida. A ferramenta Porter Stemmer piora o isolamento ao reduzir *cylindrical* para *cylindr* e *cylinders* para *cylind*.

As limitações decorrem da estrutura de bolsa de palavras. A divisão de compostos hifenizados melhora a recuperação global, mas atesta que aproximações estritamente lexicais podem inflar pontuações de arquivos desconexos.

5 CONSIDERAÇÕES FINAIS

O desempenho de ambos os modelos comprova o equilíbrio metodológico. O BM25 prioriza a ordenação exata de relevantes, enquanto o Modelo Vetorial otimiza o volume de recuperação bruta. A saturação matemática do BM25 penaliza abusos de frequência. A similaridade do cosseno beneficia materiais curtos e pontuais. A divisão dos compostos hifenizados melhora substancialmente os resultados. O ajuste empírico de parâmetros favorece o BM25, embora a normalização ideal exija informações prévias sobre o tamanho da resposta correta. O impacto dos sinônimos revela a alta sensibilidade do modelo probabilístico. A superação dos falsos positivos e negativos requer a implementação futura de recursos semânticos avançados.

6 USO DE FERRAMENTAS DE IA

O assistente Claude (Anthropic) atuou no suporte ao desenvolvimento do projeto:

- **Depuração:** Resolução de divisões por zero no BM25, detecção de falhas no filtro alfabético e estabilização de índices baseados em dicionários aninhados.
- **Reestruturação:** Otimização do fluxo de carga de arquivos para garantir reprodutibilidade linear.

- **Padronização e clareza:** Adequação da linguagem do relatório final e normalização de comentários no código.

A equipe declara autoria primária e compreensão integral de todas as fórmulas e códigos apresentados no estudo.




Figura 1: MAP por configuração de pré-processamento nos dois modelos.




Figura 2: Diferença de AP por consulta (BM25 - Vetorial).




Figura 3: MAP e NDCG@10 para as nove combinações de parâmetros.